

智检演化 130

面向少样本新产品的可信双模实时 AOI 系统

EvoInspect-130

0.9224	166.2 ms
PatchCore Overall F1	GTX2060 端到端 p95
精度模式	实时模式
2.67%	0.9474
GuardedAdapt 有害更新率	实拍视频事件 F1

团队：Cuisine 队长：崔明浩

西安交通大学 单人团队，全部工作由崔明浩独立完成

公开数据结果、真实硬件时延、反馈回放和视频 GT 均有机器可读证据。

1 工业痛点与赛题约束

1.1 少样本新产品为什么难

工业新产品上线时，正常样本易获得，缺陷类型却稀缺且持续变化。传统规则 AOI 需要反复开发；直接在线更新又可能因误标破坏历史能力。EvoInspect-130 把外观检测、装配逻辑、实时部署与反馈安全纳入同一离线系统。

100 正常+30 缺陷	图像+视频	1000+测试	GTX2060	操作员反馈
快速适配	外观与工序	严格隔离	目标<200ms	门禁与回滚

1.2 官方能力覆盖矩阵

官方能力	系统模块	证据
表面/外观缺陷	PatchCore / EfficientAD-M	MVTec AD 15 类，75/45 runs
100+30 少样本	独立支持集与固定阈值	支持、测试输入、真值三方隔离
缺件/重复/顺序	组件检测 + FSM	5 段实拍，事件 F1 0.9474
实时与小模型	EfficientAD-M ONNX FP16	真实 2060，p95 166.2ms
反馈自学习	GuardedAdapt	75-run 回放，接受率 85.33%
解释与追溯	热力图、事件、版本日志	统一 InferenceEngine 输出

1.3 数据纪律

零测试泄漏：所有测试分数和决策落盘后才读取独立真值；测试标签不参与阈值、模型选择或早停。

边界明确：MVTec 是公开基准；视频是固定机位桌面功能验证；2500 输入重采样至模型分辨率。

2 双模检测与可信闭环架构

2.1 一个接口，四条能力支路

模式	核心实现	输出与定位
Accuracy	PatchCore 正常记忆库与最近邻距离	高精度外观异常分数、热力区域、最近正常证据
Realtime	EfficientAD-M 教师—学生 + 自编码器，ONNX FP16	2060 实时分数、区域、置信度和分阶段时延
Video	OpenCV 组件检测 + 确定性 FSM	step、skip、repeat、reorder、missing、unknown 区间
Feedback	GuardedAdapt 候选生成、锚点门禁和回滚	接受/拒绝原因、版本、变更记录和恢复点

2.2 统一在线流程

输入	显式路由	本地推理	结构化输出	安全反馈
2500 图像/视频	Accuracy 或 Realtime	不依赖远程 API	分数 · 区域 · 事件 · 版本 · 时延	候选→门禁→发布/回滚

2.3 核心创新与系统贡献

- 核心创新——可信反馈发布：将操作员反馈转化为候选更新，通过反馈收益和历史锚点双门禁决定发布或回滚，使自学习过程可拒绝、可审计、可恢复。
- 精度—速度双模：同一接口按场景显式切换高精度记忆方法与 2060 实时学生模型，禁止静默 fallback。
- 图像—视频闭环：外观区域与装配步骤事件使用同一版本化结果结构。

2.4 工程边界

最终推理完全离线，不运行大语言模型或扩散模型；模型、配置、数据来源和时延口径可追溯。Accuracy/Realtime 由调用方明确选择，避免失败模式被隐藏。

3 精度—速度主结果

3.1 MVTec AD 100+30 式隔离评测

模式/模型	Overall F1	Unseen F1	Image AUROC	定位
PatchCore				
15 类×5 seeds	0.9224	0.8715	0.9817	精度模式
EfficientAD-M				
15 类×3 seeds	0.9036	0.8210	0.9569	实时模式
EfficientAD-S 15 类×1 seed	0.8908	0.7988	0.9639	速度对照

PatchCore 全像素 AUROC 0.9811、AUPRO@0.30 0.9342、AUPRO@0.05 0.7241。均为公开 MVTec AD，不代表官方隐藏集成成绩。

3.2 真实 GTX2060，2500×2500 重采样，batch=1

实现	model-only p95	end-to-end p95	结论
EfficientAD-M ONNX FP16	19.4ms	166.2ms	达到 200ms 目标
EfficientAD-S ONNX FP16	8.2ms	151.3ms	更快，质量较低
EfficientAD-M PyTorch FP32	62.9ms	331.3ms	说明部署优化必要

口径包含解码、预处理/传输、模型、后处理和序列化；100 次预热、1000 次重复；设备为真实 6GB GTX2060。

精度—速度折中：实时模式在真实 GTX2060 上实现端到端 p95 166.2ms 和 Overall F1 0.9036；对高风险、高精度工位可显式切换 PatchCore，形成可审计的质量—节拍选择。

3.3 可复现性

数据分割、配置、checkpoint、预测和硬件报告均留存机器证据；已在全新目录和 Python 3.11 环境完成一次 README 复现。EfficientAD 固定 Anomalib 2.3.0 及对应上游提交。

4 GuardedAdapt：反馈更新安全门

4.1 候选发布，而非直接改写线上模型

操作员反馈	候选阈值	反馈收益检查	历史锚点门禁	发布/回滚
误检/漏检	有界移动	新切片是否改善	历史能力是否受损	保存版本与原因

反馈先产生候选；只有反馈切片具备收益且历史锚点退化不超限才接受。否则 Champion 保持不变，并记录拒绝原因和恢复点。

4.2 75 个真实分数流离线回放

策略	有害更新率	接受率	解释
NoUpdate	0%	0%	安全但无法学习
NaiveUpdate	9.33%	100%	无约束直接更新
ThresholdUpdate	6.67%	100%	有界阈值调整
GuardedAdapt	2.67%	85.33%	兼顾更新与历史保护
71.4%			
相对 NaiveUpdate 减少有害更新		100%	11/11 拒绝更新回滚成功

4.3 证据边界

实验使用 MVTEC 固定 PatchCore 真实预测分数和确定性反馈切片，是离线回放而非生产用户研究；结论是降低有害更新概率和保护历史能力，不宣称生产准确率提升。

5 实拍闭环、落地价值与边界

5.1 五段桌面装配视频

场景	目标事件	事件 F1
正常： cup→bottle→mouse	3 个 step_completed	1.000
次序颠倒	reorder + 正常收尾	1.000
缺少 mouse	missing	1.000
bottle 重复装配	repeat	1.000
返工后恢复	step_completed + repeat	0.800
Micro 汇总	19 个 GT 匹配 18 个	0.9474

冻结人工 GT 采用±0.5 秒容差和一对一最大二分匹配。唯一错误来自前端暂不识别 REMOVE 动作。

5.2 交付形态

现场推理	反馈闭环	审计追踪	离线部署
图像/视频、模式切换、JSON 与热力图	候选接受、拒绝或回滚	模型版本、配置、原因、时延	ONNX 模型、示例、模型卡、一键说明

5.3 适用边界

- MVTec AD 不是官方隐藏测试，最终准确率以组织方测试为准。
- 视频是 5 段固定机位桌面功能验证，不外推跨产线工业泛化。
- 2500 输入重采样到 256，尚未验证原生高分辨率微小缺陷收益。
- 实时模式 AUROC 和 Unseen F1 低于内部研究门，精度优先时选择 PatchCore。

项目价值：在少样本新产品上显式切换精度/实时模式，识别装配逻辑，并让人工反馈在安全门内逐步演化。

参考资料

[1] 华为《可自学习的 AOI 实时在线 AI 质检》；[2] Roth et al., PatchCore, CVPR 2022；[3] Batzner et al., EfficientAD, WACV 2024；[4] MVTec AD。机器证据见辅助材料 evidence_summary。